

在线评测系统实验报告

Atelier OJ · 实验二 · v1.2.0 修复候选版

项目	内容
姓名	_____
学号	_____
班级	_____
GitHub	jsonpiggg/Online-Judge-System
完整评测环境	Ubuntu / WSL2, Python 3.12.3, 系统 g++, C++14
界面开发环境	Windows, React 19、TypeScript、Vite 8、FastAPI
报告日期	2026-09-05

本报告描述实际代码和已执行的测试，不代表助教最终评分。课程说明以 [2026-python 分支](#) 为准。最终提交仍需遵守课程指定仓库、网络学堂和线下验收要求。

当前自动测试、Linux 真实 runner、普通用户和管理员浏览器链路均已验证。三档响应式尺寸及危险操作二次确认已复验；外部真实模型供应商因没有用户密钥而明确列为未验收项，不用 mock 结果替代该结论。

1. 目标、架构与评分点

系统保留课程要求的 Python 后端。默认网页由 FastAPI 同源提供 React 构建产物，通过 HttpOnly Session Cookie 调用 REST API；FastAPI 使用 async def 路由，依赖注入完成鉴权，后台 asyncio Task 负责评测和命题。Streamlit 保留为兼容入口。阻塞文件操作、密码哈希、DNS 查询使用线程卸载，SQLite 通过 aiosqlite 访问。

模块	分值	实现及证据
Step 1	5	独立 JSON、加载校验、CRUD、原子替换；test_problems、test_core_edges
Step 2	5	Python/C++14、语言模板注册、逐点评测及资源限制；test_linux_judge、test_judge_regressions
Step 3	5	pending、组合查询、分页、本人/管理员权限、重测；test_submissions、test_api_edges
Step 4	5	bcrypt、Session、角色、统计、独立角色审计；test_auth_users、test_role_audit
Step 5	5	私有/公开测试点日志、200/403 访问审计；test_logs_reset、test_api_edges
Step 6	5	账户、题库、纵向做题、Monaco 编辑器、命题与管理中心；Vitest 及三尺寸 Playwright 验收
AI R1-R4	4	可读工作台、自定义加密配置、进度与取消、Token/费用；真实 HTTP/SSE mock 自动测试
AI 质量与易用性	6	二次批判、独立 oracle 随机对拍、mutation score、版本化草稿与编辑器局部入口；真实供应商质量未验收
代码规范	5	分层结构、Ruff/mypy、uv.lock、CI、分阶段真实 PR；不以自动检查代替代码理解
实验报告	5	架构、难点、测试证据、真实截图、AI 使用说明与改进建议

目录分工：src/oj/routers 保存业务接口；auth、security、database、problem_store、judge、submissions、ai_authoring、ai_transport 分别负责领域功能。web/src 按账户、题库、编辑器、记录、管理、AI 页面与共享组件拆分；frontend 保留兼容入口；data/problem_seeds 保存可恢复的演示题。

2. 数据、权限与接口

混合存储与无损迁移

每题一个 JSON 文件。安全题号只允许字母、数字、下划线和连字符；保存前经 Pydantic 校验。同目录临时文件写入、fsync、原子替换及异步锁保证写入完整性。输入、输出、代码和密码不自动 strip，保留有意义的空白。

SQLite 在原有业务表外新增 workspace_drafts、problem_drafts、problem_draft_revisions 和 verification_runs。源码草稿按用户、题目和语言隔离；命题草稿采用 revision 乐观锁并保存完整快照。PRAGMA user_version 7 增加做题会话上下文代次；升级前生成 SQLite 备份，reset 不承担迁移职责。

题目限制内部允许未设置，JSON 中保持省略。评测逐项使用“题目显式值、语言值、系统 3 秒/128 MB”的顺序。课程 GET 接口仍展示默认值，额外 limit_inheritance 字段供编辑器区分继承与显式配置，不猜测旧数据的原始意图。

身份与权限

启动保留指定管理员 admin / admintestpassword。密码使用 bcrypt，随机 Session ID 存在服务端数据库中；登录轮换，退出删除，Cookie 设置 HttpOnly、SameSite 和有效期。每次访问重新检查用户角色，因此已有会话被禁用后也返回 403。

普通用户可添加/编辑题目、创建语言、提交代码；管理员拥有删除题目、修改角色、重测、日志公开、全站审计和重置权限。通用题目编辑也不能绕过日志公开权限。角色修改与操作审计在同一事务内提交，不混入课程要求 action=view_logs 的访问日志。前端在同一账号重新登录时保留草稿；切换账号时清除工作区、题目编辑器和 AI 瞬态状态，避免同一浏览器会话跨账号展示源码或命题结果。

响应统一为 code、msg、data，实际 HTTP 状态码与 code 一致。校验错误由 422 转为 400；对可识别的越权范围，在分页校验前返回 403。未登录、无权限、参数错误、限频、冲突、不存在和内部异常分别覆盖对应优先级测试。

查询与审计

提交列表默认遵守一级条件不可全空、page/page_size 组合语义，只返回列表摘要。前端管理员通过可选 all_users 扩展查询全站；include_metadata 仅增加展示所需元数据，源码只出现在有权限的详情中。用户统计按提交计数，已通过题目按题号去重。

本人和管理员可以查看逐点日志；题目公开后其他登录用户也能查看日志，但仍不能读取私有提交概要。存在且有效的日志访问分别记录 200/403；未登录、非法参数或不存在的记录不写审计。API 默认不返回内部异常、密钥或服务端临时路径。

3. 异步评测与一致性

提交先落库为 pending，再启动后台 Task，接口不等待判题结束。重启恢复 pending 提交；重新评测先取消旧任务，再清理并覆盖同一 submission_id。正常评测完成是 success，不等于全部 AC；基础设施错误才是 error。界面分别显示“全部通过”“评测完成·未全部通过”和“评测服务异常”。

默认 Python 直接执行，C++14 经 g++ 编译。命令模板扩展为 argv，不使用 shell；只接受安全可执行程序 and src/exe 占位符。每次评测使用独立临时目录作为工作目录、最小环境、进程组。Linux 以 RLIMIT_AS、RLIMIT_FSIZE、禁用 core dump、墙钟超时、进程树 RSS 监控及子进程数量上限约束运行。

stdout/stderr 各并发分块读取，分别最多保留 1 MB；超限立即终止整个进程组并返回 UNK。编译同样有界读取，超时或洪泛返回 CE。取消和超时会等待管道排空、回收进程并清理临时目录。编译和运行诊断中的临时工作路径被替换为 workspace 标记。

输出比较忽略行末空白及最终多余换行，其他字符严格匹配。每个 AC 测试点 10 分，counts 为测试点数量乘 10。各点独立记录 verdict、耗时、内存和裁剪后的诊断。

测试发现原有“查询次数后再插入”的实现可被 6 个并发请求同时绕过。现以单 worker 的 intake_lock 包住限频检查和创建，实测恰好 3 个成功、3 个 429。reset 先取消 AI 和评测任务，再清理数据，避免旧任务在 ID 重用后写回新记录。

这些限制是课程级防护，不是生产级沙箱。任意代码仍可能访问同一用户权限下的文件或网络；默认只能在可信本机、单 worker、localhost 环境运行，不能直接公开部署。

4. AI 命题与安全

生成、批判和本地验证

用户输入知识点、难度、约束和可选参考题。第一阶段真实流式调用生成完整题目，第二阶段再次真实调用，批判知识点匹配、边界、规模和错误算法并返回改进后的完整结果。没有自动重试付费请求。

生成结构必须包含题目、Python 参考解、审查、基础/边界/规模覆盖说明，以及至少两种不同的典型错误算法。测试输入不少于 5 个且不能重复。参考解必须通过全部样例与测试点；每种错误解必须被至少一个 WA/TLE/MLE 测试点拒绝，CE、RE 或 UNK 不能充当有效卡错证据。失败保留诊断，但不提供一键入库。

通过基础验证后，独立暴力解与参考解对数据生成器产生的 20–100 组受限唯一输入进行对拍；生成器本身使用同一 runner 的超时、内存、进程和输出上限。典型错误解的实际杀伤率形成 mutation score。只有对拍通过且 mutation score 为 100% 的关联草稿进入 ready，发布仍要求显式操作。命题编辑器可按题面、约束、样例、测试点或审查范围发起任务，结果、费用、完整资产和版本历史在刷新后恢复。

实时状态、取消与费用

阶段分别为分析、生成、批判、参考解验证、错误解验证和完成。前端 fragment 轮询真实后台状态，终态后停止定时轮询。取消会取消后台 Task、退出 HTTP 流并终止验证子进程。总任务默认 300 秒、每阶段 120 秒；重启将遗留 AI 任务标记失败，不再次收费执行。

两次调用的输入/输出用量累加。优先采用服务商 usage；缺失时按提示词和输出 UTF-8 字节数除以 4 估算并明确标注，不能等同精确账单。流中阶段用量每约 0.5 秒保存，结束校正；取消和失败保留已观察用量。费用为输入 Token/单位×输入价，加输出 Token/单位×输出价，任务持久化相应计价依据。

密钥和外部连接

模型、URL 和密钥来自用户配置，不硬编码供应商。GET 配置只返回 api_key_configured 等非敏感字段，更新可以保留原密钥。环境主密钥派生 Fernet 加密密钥；未配置时持久化到运行目录 .ai-key，重启后仍可解密，备份和迁移时必须一并保留。

默认 HTTPS、公网地址、禁止重定向和环境代理。连接前校验 DNS 全部答案，将数字 IP 固定为实际连接目标，同时保留原域名的 Host、SNI 和证书验证。SSE 事件及总传输量均受限。内网开关仅用于明确的本地 mock 测试，默认关闭。

5. 真实测试结果与限制

当前 Windows / Python 3.14 全量回归为 227 passed、10 个 Linux 专用测试 skipped；后端行覆盖率 96.54%、分支覆盖率 90.33%，Ruff、mypy 和 git diff 检查通过。Linux CI 在每个 PR 和合并后的 main 复跑完整质量门禁，最终状态以 GitHub Actions 记录为准。

测试范围	证据
Python verdict	实际执行 AC、WA、RE、TLE、MLE、UNK
C++14 verdict	实际编译/执行 AC、WA、CE、RE、TLE、MLE
运行边界	空白保真、限制继承、输出洪泛、编译超时、取消清理
API	Session 轮换/过期/禁用、权限、状态码、分页、并发限频、重测、reset、审计
存储	旧库数据保留、迁移备份和幂等、原子写失败、路径限制
AI	真正本地 HTTP/SSE 服务：两次请求、缺 usage 估算、取消、超时、坏 JSON、参考/错误解失败
Streamlit	导航角色差异、可视化编辑块、登录错误、401 草稿保留、AI 导入新增/更新
依赖	升级 cryptography/pytest/pip，锁定 uv.lock；扫描前 16 条已知漏洞，升级后 0 条


浏览器 20 条 Playwright 流程已实际完成：1440、1024、390px 题库、纵向工作区、提交、命题、资源、账户与管理页面；三档均无页面级横向溢出。普通用户实际注册、登录、提交、恢复草稿、管理题目与评测语言，并以第二个普通账号查看公开逐点日志且页面不出现源码；管理员实际修改角色、公开日志、重测并检查危险操作确认。AI mock 在 UI 中完成完整命题、未完成草稿补全、Code Review 差异、流式恢复、历史折叠、新话题与取消。进行中任务标签的关闭与重新进入恢复、手工题的修复入口与无参考解基础检查也由真实浏览器覆盖。截图为浏览器原始输出，不使用绘制界面替代。

浏览器与启动验收还发现三个自动测试外问题并在发布前修复：启动脚本显式注入仓库根目录 PYTHONPATH，解决直接运行 Streamlit 的包导入失败；.gitattributes 强制 shell 脚本使用 LF，解决 Windows Git 下 WSL 将 EXIT\r 识别为非法 signal；切换不同账号时清除私有瞬态状态，解决同一 Streamlit 会话沿用前一账号草稿的问题。修复后 scripts/run.sh 实际启动的 API /docs 与 Streamlit health 均返回 200。真正删除和 reset 由 API 自动测试执行；浏览器只验证确认文字、输入门槛、取消无副作用，未破坏最终截图数据集。

真实供应商未验收：用户未提供可用模型密钥，因此没有证明任何特定模型在复杂课程题目的实际输出质量。mock 仅证明协议、流程、取消、计算及本地校验工作，不证明真实模型能力。

6. 界面成果

默认 React 网页采用紧凑浅色工具风，正文基准 16px，导航、按钮、表格和辅助信息独立保持 14px，使用浅蓝点缀、细边框和低强度阴影。题库直接显示题号、难度与学习状态；工作区按题面、代码、结果和 AI 纵向排列；记录页提供组合筛选和统一分页。主导航下方保留可关闭的进行中题目、草稿、提交与 AI 任务入口。所有用户可从“资源”导航集中查看、创建和编辑题目、配置评测语言并查询公开日志，管理员管理中心只承载删题、全站提交、用户角色、日志公开、审计和重置等特权操作。做题助手固定显示输入区与最新回答，旧轮次折叠分页，并支持开启不继承旧上下文的新对话。命题中心支持未完成草稿、AI 补全、Code Review 差异及基础/完整两档验证，所有课程得分点的网页入口见 [实验功能与 React 网页覆盖核对](#)。



1440×900：桌面工作区，C++14 实际提交 #4 全部通过；截图位于工作区中段

<> Atelier OJ

A admin

📖 题库

📄 我的提交

🏆 命题中心

<> 资源

🔒 管

进行中

▶ 提交 #3 ×

<> sum_2 · 两... ×

< 返回提交列表

提交 #3

📄 提交详情

返回题目继续修改

题号 sum_2 · admin · python · 9/5/2026, 12:32:10 AM

📄 评测结果

✓ 全部通过

3 / 3

30 / 30

测试点通过

得分

测试点

全部

未通过

#1 ✓

AC

通过

#2 ✓

AC

通过

#3 ✓

AC

通过

▶ 原始运行日志

▼ 提交代码

a,b=map(int,input().split());print(a+b)

复制

重新评测

390×844: 手机题库, 筛选折叠且页面无横向溢出

Atelier OJ
编程练习空间

题库我的提交命题中心资源管理

admin
管理员

进行中<div>sum_2: 两数之和</div>

命题中心

手动创建题目

描述你想出的题目

例如：面向初学者的前缀和题目，使用生活场景，包含清晰的样例和边界测试。

题面与解法 → 测试设计 → 复审验证。必要时最多自动修复一次，将产生模型调用费用。

开始生成

我的草稿

草稿中的两数之和编辑中 · 版本 3

浏览器验收求和题可发布 · 完整验证 · 版本 3

浏览器验收求和题已发布 · 版本 1

区间求和编辑中 · 版本 2

AI 任务

局部建议已复审，待采纳后重新验证9/5/2026, 12:32:04 AM

命题完成并通过参考解法验证9/5/2026, 12:31:49 AM

命题完成并通过参考解法验证9/5/2026, 12:31:42 AM

命题中心：草稿与任务历史入口；未配置真实供应商时如实显示未配置

7. 工程过程与 AI 使用说明

保留 v1.0.0 历史。v1.1 修复按 PR #9 评测正确性、#10 前端基础、#11 前端 workflow、#12 AI 质量、#13 安全加固推进，均在各阶段 CI 成功后以 merge commit 合并。最终测试/报告由 test/v1.1-release 收口，CI 通过后以 merge commit 合并并发布 v1.1.0；SHA 与发布状态以 GitHub 不可变记录为准，不伪造提交时间或通过状态。

本项目由用户确定目标、审核计划和提出交互问题，Codex 辅助生成和修改代码、编写测试、执行命令、操作 GitHub、浏览器验收及报告排版。代码辅助比例很高，绝大多数实现由 AI 辅助完成；没有逐行作者追踪，不能提供可信的精确百分比。用户提交课程作业前仍需理解架构、异步取消、权限边界及测试局限。

工作流为需求核对、阶段实现、失败回归、修复、Linux 自动测试、真实浏览器检查、PR/CI、文档。实际发现并修复的难点包括空白丢失、限制继承、输出缓冲无界、组件注册上下文、跨页草稿状态、并发限频、错误优先级、SQLite 游标与迁移、AI 真实双阶段和 DNS 重绑定风险。

时间投入以真实 Git 和工具记录为准，本报告不虚构人工工时。进一步改进应优先考虑容器/cgroup/seccomp 沙箱、恶意提交隔离、真实供应商质量评估、更广泛的辅助技术与浏览器测试；不应以增加比赛、排行榜等无关功能替代当前课程要求。